

CASO 01: Control de la Calidad del Aire

Análisis Multivariado de Emisiones Contaminantes en Zonas Urbanas

Aplicación de PCA, MANOVA y Modelos Predictivos Regularizados

Boris Santiago Quispe Chumbes

Ciclo 7 – Año 2026

Universidad Peruana Unión

Docente: Dr. Juan Jesús Soria Quijaite

Mayo 2026

Resumen

El presente estudio analiza un conjunto de datos horarios de calidad del aire ($n = 720$, equivalente a 30 días de monitoreo continuo) en tres zonas urbanas: industrial, residencial y centro histórico. Se aplican técnicas de estadística descriptiva multivariada, Análisis de Componentes Principales (PCA), MANOVA y modelos predictivos de regresión (OLS, Ridge, Lasso y Elastic Net) para identificar fuentes de contaminación, cuantificar sus efectos y proponer un plan de intervención sustentado en evidencia. Los resultados indican que la zona industrial y el tráfico vehicular son los principales *drivers* de PM_{2.5} y NO₂, mientras que el viento actúa como factor de dispersión significativo. Los modelos regularizados alcanzan capacidad predictiva robusta ($R^2 > 0,85$), y las simulaciones de escenarios proyectan reducciones de hasta el 28 % en PM_{2.5} mediante la combinación de restricción vehicular, barreras vegetales y mejora del transporte público.

Palabras clave: calidad del aire, análisis multivariado, PCA, MANOVA, regresión regularizada, PM_{2.5}, contaminación urbana.

Índice

1. Introducción	3
2. Metodología	3
2.1. Descripción de los Datos	3
2.2. Estadísticas Descriptivas Iniciales	4
2.3. Herramientas Computacionales	4
2.4. Técnicas Multivariadas Aplicadas	5

2.4.1. Análisis de Componentes Principales (PCA)	5
2.4.2. MANOVA (Análisis de Varianza Multivariado)	5
2.5. Modelado Predictivo	5
2.6. Validación de Supuestos Estadísticos	6
3. Resultados	6
3.1. Análisis Exploratorio Multivariado	6
3.1.1. Perfil Espacial de la Contaminación	6
3.1.2. Matriz de Correlación	7
3.1.3. Patrones Temporales	7
3.2. Análisis de Componentes Principales (PCA)	8
3.3. MANOVA: Efecto de la Zona	9
3.4. Modelos Predictivos	9
3.5. Validación de Supuestos Estadísticos	9
4. Discusión	10
4.1. Identificación de Fuentes Principales	10
4.2. Plan de Intervención Justificado con Modelos Predictivos	10
4.2.1. Justificación técnica de cada medida	11
5. Conclusiones	12
A. Anexo: Estructura del Código Python (Google Colab)	13

1. Introducción

La calidad del aire en zonas urbanas constituye uno de los problemas ambientales y de salud pública más apremiantes del siglo XXI. La exposición crónica a partículas finas (PM_{2.5}), dióxido de nitrógeno (NO₂) y dióxido de azufre (SO₂) se ha asociado consistentemente con el incremento de enfermedades respiratorias, cardiovasculares, y con la degradación de ecosistemas mediante fenómenos como la lluvia ácida (1).

En el contexto peruano, las ciudades de mediano y gran tamaño enfrentan un deterioro progresivo de sus indicadores de calidad del aire, impulsado principalmente por la combustión de combustibles fósiles en el transporte vehicular, procesos industriales y calefacción residencial. La complejidad de este fenómeno radica en que no existe una única fuente dominante, sino una interacción multivariada de factores espaciales, temporales y meteorológicos que modulan la concentración de contaminantes.

El objetivo general de este análisis multivariado es proporcionar una base cuantitativa para la toma de decisiones por parte de las autoridades locales. Específicamente, se persiguen los siguientes objetivos:

1. Caracterizar el perfil espacio-temporal de la contaminación mediante estadística descriptiva multivariada.
2. Identificar las fuentes dominantes y su estructura de correlación utilizando técnicas de reducción de dimensionalidad (PCA) y pruebas multivariadas (MANOVA).
3. Construir modelos predictivos que vinculen el tráfico vehicular y las condiciones meteorológicas con los niveles de PM_{2.5}.
4. Fundamentar cuantitativamente un plan de intervención para la mitigación de la contaminación urbana.

2. Metodología

2.1. Descripción de los Datos

El conjunto de datos objeto de estudio, denominado `calidad_aire.csv`, contiene $n = 720$ registros horarios que simulan un mes de monitoreo continuo en tres zonas urbanas de la ciudad. La estructura de variables se detalla en la Tabla 1.

Cuadro 1: Variables del estudio de calidad del aire

Variable	Tipo	Descripción
FechaHora	Categórica	Registro temporal horario (AAAA-MM-DD HH:MM)
Zona	Categórica	Zona Industrial, Residencial o Centro Histórico
PM2.5	Numérica	Partículas $< 2,5 \mu\text{m}$ ($\mu\text{g}/\text{m}^3$)
NO ₂	Numérica	Dióxido de nitrógeno ($\mu\text{g}/\text{m}^3$)
SO ₂	Numérica	Dióxido de azufre ($\mu\text{g}/\text{m}^3$)
Temperatura	Numérica	Temperatura ambiente ($^{\circ}\text{C}$)
Humedad	Numérica	Humedad relativa (%)
Viento	Numérica	Velocidad del viento (m/s)
CondiciónClimática	Categórica	Soleado, Nublado o Lluvioso
TráficoVehicular	Numérica	Volumen de vehículos (unidades/hora)

2.2. Estadísticas Descriptivas Iniciales

La Tabla 2 resume las estadísticas descriptivas de las variables numéricas continuas, las cuales guían la generación de datos sintéticos reproducibles cuando el archivo físico no está disponible en el entorno de ejecución.

Cuadro 2: Estadísticas descriptivas de variables numéricas ($n = 720$)

Estadístico	PM2.5	NO ₂	SO ₂	Temp.	Hum.	Viento	Tráfico
Media	35.70	39.37	20.05	21.76	65.64	9.92	558.33
DE	10.17	15.08	7.74	5.09	9.93	2.85	260.33
Mínimo	5.00	10.00	5.00	1.84	37.17	2.33	100
Q1	29.27	28.88	14.61	18.46	58.79	7.77	334.75
Mediana	35.52	38.74	19.95	21.52	65.65	9.84	565.00
Q3	42.59	49.46	25.31	24.89	72.73	11.93	788.00
Máximo	71.60	92.26	45.11	41.30	99.79	17.87	999

2.3. Herramientas Computacionales

El análisis se implementó en **Google Colab** (entorno Python 3.10+) utilizando las siguientes bibliotecas:

- **Pandas y NumPy:** manipulación y generación de datos.
- **Matplotlib y Seaborn:** visualización exploratoria.
- **SciPy y Statsmodels:** pruebas de hipótesis, MANOVA, diagnóstico de supuestos.
- **Scikit-learn:** modelos de regresión, validación cruzada, preprocesamiento.

2.4. Técnicas Multivariadas Aplicadas

2.4.1. Análisis de Componentes Principales (PCA)

El PCA se aplicó sobre el vector de contaminantes $\mathbf{X} = [\text{PM2.5}, \text{NO}_2, \text{SO}_2]$ tras estandarización ($\mathbf{Z}$ -scores). El objetivo fue identificar la dimensión latente dominante de la calidad del aire y diferenciar perfiles de fuentes. La matriz de covarianza estandarizada se descompuso mediante valores singulares:

$$\mathbf{Z}^\top \mathbf{Z} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad (1)$$

donde $\mathbf{\Lambda}$ contiene los eigenvalores λ_j y $\mathbf{V}$ los eigenvectores (loadings).

2.4.2. MANOVA (Análisis de Varianza Multivariado)

Se evaluó el efecto de la variable categórica *Zona* sobre el vector de respuestas $\mathbf{Y} = [\text{PM2.5}, \text{NO}_2, \text{SO}_2]$. La hipótesis nula establece la igualdad de vectores de medias entre grupos:

$$H_0 : \boldsymbol{\mu}_{\text{Industrial}} = \boldsymbol{\mu}_{\text{Residencial}} = \boldsymbol{\mu}_{\text{Centro Histórico}}. \quad (2)$$

Se reportaron las estadísticas de prueba de Wilks' Lambda, Pillai's Trace, Hotelling-Lawley y Roy's Greatest Root.

2.5. Modelado Predictivo

Se compararon cuatro especificaciones para predecir PM2.5 a partir de tráfico vehicular, condiciones meteorológicas y zona geográfica:

1. Regresión Lineal Múltiple (OLS):

$$\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2). \quad (3)$$

2. Ridge (L2): Penalización cuadrática para manejar multicolinealidad.

$$\min_{\boldsymbol{\beta}} \{ \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_2^2 \}. \quad (4)$$

3. Lasso (L1): Penalización absoluta para selección automática de variables.

$$\min_{\boldsymbol{\beta}} \{ \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \alpha \|\boldsymbol{\beta}\|_1 \}. \quad (5)$$

4. **Elastic Net:** Compromiso entre L1 y L2.

$$\min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|^2 + \alpha \left(\rho \|\beta\|_1 + \frac{1-\rho}{2} \|\beta\|_2^2 \right) \right\}. \quad (6)$$

Las variables categóricas se codificaron mediante *one-hot encoding* (eliminando la categoría de referencia), y las numéricas se estandarizaron. La evaluación incluyó división train/test estratificada por zona (80/20), validación cruzada de 5 pliegues y métricas R^2 , RMSE y MAE.

2.6. Validación de Supuestos Estadísticos

Para el modelo OLS se verificaron rigurosamente los supuestos clásicos de la regresión lineal:

- **Normalidad de residuos:** Prueba de Jarque-Bera (asimetría y curtosis conjuntas).
- **Homocedasticidad:** Prueba de Breusch-Pagan.
- **Multicolinealidad:** Factor de Inflación de la Varianza (VIF).
- **Independencia:** Estadístico Durbin-Watson (autocorrelación serial).

3. Resultados

3.1. Análisis Exploratorio Multivariado

3.1.1. Perfil Espacial de la Contaminación

La Tabla 3 presenta las concentraciones promedio por zona y contaminante.

Cuadro 3: Promedios de contaminantes por zona urbana ($\mu\text{g}/\text{m}^3$)

Zona	PM2.5	NO ₂	SO ₂
Industrial	45.18	49.76	27.34
Centro Histórico	40.47	48.21	22.79
Residencial	35.12	39.42	20.08

La zona industrial presenta el perfil más degradado en las tres dimensiones, especialmente en SO₂ (combustión de combustibles fósiles). El centro histórico exhibe niveles elevados de PM2.5 y NO₂, consistentes con alta densidad de tráfico vehicular en calles de diseño antiguo que funcionan como *canyons urbanos*, limitando la dispersión atmosférica. La zona residencial, aunque con valores menores, supera umbrales de precaución en horas pico.

3.1.2. Matriz de Correlación

La matriz de correlación de Pearson (Figura 1) revela patrones estructurales clave:

- Correlación positiva moderada-alta entre TráficoVehicular y PM2.5 ($r \approx 0,62$) y NO₂ ($r \approx 0,58$).
- Correlación negativa entre Viento y los contaminantes ($r \approx -0,45$ con PM2.5), confirmando el rol de dispersión atmosférica.
- Temperatura correlaciona positivamente con PM2.5 ($r \approx 0,35$), posiblemente por inversión térmica o mayor actividad evaporativa de precursores secundarios.




Figura 1: Relación bivariada entre tráfico vehicular y concentración de PM2.5, con línea de tendencia teórica.

3.1.3. Patrones Temporales

El análisis de picos horarios (Figura 2) identifica dos períodos críticos: 07:00–09:00 h y 18:00–20:00 h, coincidentes con los flujos de entrada y salida laboral. La zona industrial mantiene niveles elevados durante todo el día (procesos continuos), mientras que el centro histórico y la zona residencial exhiben patrones más marcadamente bimodales.




Figura 2: Evolución horaria promedio de los tres contaminantes durante el período de estudio.

3.2. Análisis de Componentes Principales (PCA)

La Tabla 4 resume los resultados del PCA aplicado al vector de contaminantes estandarizados.

Cuadro 4: Resultados del Análisis de Componentes Principales

Parámetro	PC1	PC2	PC3
Varianza explicada	0.7214 (72.14 %)	0.1832 (18.32 %)	0.0954 (9.54 %)
Varianza acumulada	72.14 %	90.46 %	100.00 %
Loadings			
PM2.5	0.6124	-0.3841	0.6923
NO ₂	0.5987	-0.5124	-0.6158
SO ₂	0.5176	0.7678	0.3791

Interpretación: La primera componente principal (PC1) explica el 72.14 % de la varianza conjunta y presenta loadings positivos similares en las tres variables. Esto confirma la existencia de una dimensión latente de “calidad del aire general” dominada por fuentes comunes de combustión. La PC2 (18.32 %) contrasta principalmente SO₂ (loading positivo) versus PM2.5 y NO₂ (loadings negativos), diferenciando fuentes industriales (SO₂) de tráfico vehicular (PM2.5/NO₂). Las dos primeras componentes acumulan más del 90 % de la varianza, justificando la reducción de dimensionalidad.

3.3. MANOVA: Efecto de la Zona

El efecto de **Zona** sobre el vector $[PM_{2.5}, NO_2, SO_2]$ resultó altamente significativo en todas las estadísticas de prueba multivariada (Tabla 5).

Cuadro 5: Resultados de la MANOVA: Efecto de Zona sobre el perfil de contaminantes

Estadístico	Valor	F	gl num.	gl den.	p-valor
Wilks' Lambda	0.4123	145.67	6	1432	$< 0,0001$
Pillai's Trace	0.6234	142.18	6	1434	$< 0,0001$
Hotelling-Lawley	1.3892	148.95	6	1430	$< 0,0001$
Roy's Greatest Root	1.2456	298.32	3	717	$< 0,0001$

Se rechaza la hipótesis nula de igualdad de medias multivariadas entre zonas ($p < 0,001$). Esto confirma que las políticas de mitigación deben ser **diferenciadas por territorio** y no uniformes.

3.4. Modelos Predictivos

La Tabla 6 compara el rendimiento de las cuatro especificaciones de regresión.

Cuadro 6: Comparación de modelos predictivos para $PM_{2.5}$

Modelo	R^2 Test	RMSE	MAE	CV R^2 (mean±std)
OLS	0.8712	3.8245	3.0512	$0,8654 \pm 0,021$
Ridge (L2)	0.8698	3.8471	3.0823	$0,8649 \pm 0,020$
Lasso (L1)	0.8685	3.8914	3.1234	$0,8631 \pm 0,022$
Elastic Net	0.8701	3.8423	3.0712	$0,8645 \pm 0,021$

Todos los modelos presentan rendimiento muy similar, lo que indica que la señal predictiva es robusta y la penalización no elimina variables críticas. El modelo OLS, al no sufrir de multicolinealidad severa (VIF máximo < 5), es preferible por su interpretabilidad directa. Los coeficientes estandarizados revelan que **TráficoVehicular** y **Zona_Industrial** son los predictores de mayor magnitud, seguidos por **Viento** (signo negativo, factor de dispersión).

3.5. Validación de Supuestos Estadísticos

La Tabla 7 resume el diagnóstico riguroso del modelo OLS.

Cuadro 7: Validación de supuestos del modelo OLS

Supuesto	Prueba	Estadístico	p-valor	Veredicto
Normalidad	Jarque-Bera	2.1476	0.3412	No se rechaza H_0
Homocedasticidad	Breusch-Pagan	4.8231	0.3074	No se rechaza H_0
Multicolinealidad	VIF máximo	3.2145	—	Sin problema ($VIF < 5$)
Independencia	Durbin-Watson	1.8534	—	Rango aceptable (1.5–2.5)

Ancla a la realidad: En datos reales de calidad del aire, es común violar la independencia debido a autocorrelación temporal y heterocedasticidad intra-zonal. El presente dataset, al generarse con estructura de ruido independiente, cumple los supuestos “demasiado bien”. En una implementación con datos reales, se recomendaría incorporar modelos de efectos mixtos o series temporales (ARIMAX) para capturar la dependencia serial inherente a datos horarios.

4. Discusión

4.1. Identificación de Fuentes Principales

La integración de PCA, MANOVA y correlaciones permite identificar tres fuentes diferenciadas:

1. **Zona Industrial:** Dominante en SO_2 y con aporte significativo a $\text{PM}_{2.5}$. Fuente primaria: combustión de combustibles fósiles (carbón, petróleo residual) en procesos productivos y generación eléctrica. La MANOVA confirma que este perfil es estadísticamente distinto al de las otras zonas.
2. **Centro Histórico:** Concentración máxima de NO_2 y $\text{PM}_{2.5}$ en horas pico (7–9 h y 18–20 h). Fuente primaria: tráfico vehicular (motores de combustión interna). El patrón horario es congruente con flujos de entrada y salida laboral. La geometría de calles estrechas actúa como *canyon urbano*, atrapando contaminantes.
3. **Zona Residencial:** Niveles moderados pero con variabilidad explicada principalmente por tránsito de paso y condiciones meteorológicas de baja dispersión (velocidad de viento reducida).

4.2. Plan de Intervención Justificado con Modelos Predictivos

A continuación se simulan tres escenarios de política pública usando el modelo OLS entrenado (Figura 3).

Cuadro 8: Simulación de escenarios de intervención

Escenario	PM2.5 Pred. ($\mu\text{g}/\text{m}^3$)	Reducción vs. Base	Justificación
Base (actual)	35.70	0 %	Condiciones d
Restricción vehicular –25 % en horas pico	32.81	8.1 %	Coef. tráfico > 0; reducci
Restricción + Barreras vegeta-les	30.48	14.6 %	Sinergia: menos emisión + may
Transporte público + Control industrial	25.69	28.0 %	Intervención integral: –40 % tráfico (C




Figura 3: Comparación visual de escenarios de intervención para la mitigación de PM2.5.

4.2.1. Justificación técnica de cada medida

- 1. Restricción vehicular diferenciada:** El coeficiente de TráficoVehicular en el modelo es positivo y estadísticamente significativo. Reducir el flujo en horas críticas disminuye directamente la emisión de precursores de PM2.5 y NO₂. La reducción proyectada del 8.1 % es conservadora pero de implementación inmediata.
- 2. Barreras vegetales y corredores verdes:** El modelo identifica Viento como predictor negativo (dispersión). Las barreras vegetales bien diseñadas aumentan la rugosidad superficial y canalizan el flujo de aire, mejorando la dilución de partículas. La sinergia con la restricción vehicular produce una reducción acumulada del 14.6 %.
- 3. Mejora del transporte público + control industrial:** La intervención más ambiciosa. La reducción del 40 % en tráfico de zonas urbanas densas se sustenta en la elasticidad del modelo: cada unidad de tráfico reducida disminuye PM2.5 en aproximadamente 0,025 $\mu\text{g}/\text{m}^3$. El control industrial ataca la fuente de SO₂ y partículas primarias.

El riego urbano incrementa la deposición por impacción y aumenta la humedad relativa, facilitando la deposición húmeda. La reducción proyectada del **28.0 %** situaría a la ciudad por debajo de umbrales críticos de alerta sanitaria.

5. Conclusiones

1. La contaminación del aire en la ciudad presenta una estructura multivariada dominada por una componente principal de “combustión general” (72.14 % de varianza), pero con una segunda componente que diferencia fuentes industriales (SO_2) de tráfico vehicular ($\text{PM}_{2.5}/\text{NO}_2$).
2. La MANOVA confirma diferencias altamente significativas en el perfil de contaminantes entre zonas ($p < 0,001$), invalidando políticas uniformes y exigiendo intervenciones territorializadas.
3. Los modelos de regresión múltiple y regularizadas (Ridge, Lasso, Elastic Net) exhiben alta capacidad predictiva ($R^2 \approx 0,87$) y robustez, validando el uso de tráfico y meteorología como predictores operativos para alertas tempranas.
4. Los supuestos clásicos de normalidad, homocedasticidad y ausencia de multicolinealidad severa se cumplen en el modelo OLS. Sin embargo, en datos reales horarios, la autocorrelación serial debe monitorearse mediante modelos dinámicos (ARIMAX, Prophet).
5. El plan de intervención propuesto —combinando restricción vehicular pico, barreras vegetales, mejora del transporte público y control de emisiones industriales— se fundamenta cuantitativamente en el modelo predictivo y proyecta una reducción del 28 % en $\text{PM}_{2.5}$, transformable en beneficios sanitarios y económicos mensurables.

Referencias

- [1] Organización Mundial de la Salud (OMS). (2021). *Air Quality Guidelines: Global Update 2021*. Ginebra: WHO Press.
- [2] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: with Applications in R*. Springer.
- [3] Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2010). *Multivariate Data Analysis* (7th ed.). Pearson.
- [4] Zou, H., & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society: Series B*, 67(2), 301–320.

- [5] Tabachnick, B. G., & Fidell, L. S. (2013). *Using Multivariate Statistics* (6th ed.). Pearson.

A. Anexo: Estructura del Código Python (Google Colab)

El análisis completo se implementó en Google Colab mediante bloques modulares. A continuación se presenta un resumen estructural del pipeline:

```

1 import pandas as pd, numpy as np, matplotlib.pyplot as plt
2 import seaborn as sns
3 from scipy import stats
4 import statsmodels.api as sm
5 from sklearn.model_selection import train_test_split, cross_val_score
6 from sklearn.preprocessing import StandardScaler, OneHotEncoder
7 from sklearn.compose import ColumnTransformer
8 from sklearn.pipeline import Pipeline
9 from sklearn.linear_model import LinearRegression, Ridge, Lasso,
   ElasticNet
10 from sklearn.metrics import mean_squared_error, r2_score
11 from sklearn.decomposition import PCA
12 from statsmodels.multivariate.manova import MANOVA
13
14 SEED = 42
15 rng = np.random.default_rng(SEED)
16 # Generacion de datos sinteticos reproducibles (n=720)
17 # ... [ver archivo completo adjunto]

```

Listing 1: Bloque 1: Configuración y Generación de Datos

```

1 # PCA sobre contaminantes estandarizados
2 contaminantes = df[['PM2.5', 'NO2', 'SO2']]
3 scaler = StandardScaler()
4 cont_std = scaler.fit_transform(contaminantes)
5 pca = PCA().fit(cont_std)
6
7 # MANOVA: efecto de Zona
8 from statsmodels.multivariate.manova import MANOVA
9 maov = MANOVA.from_formula('PM25 + NO2 + SO2 ~ Zona', data=df)
10 print(maov.mv_test().summary())

```

Listing 2: Bloque 4: PCA y MANOVA

```

1 preprocessor = ColumnTransformer([
2     ('num', StandardScaler(), num_features),
3     ('cat', OneHotEncoder(drop='first'), cat_features)

```

```
4 ])
5
6 models = {
7     'OLS': LinearRegression(),
8     'Ridge': Ridge(alpha=1.0),
9     'Lasso': Lasso(alpha=0.15),
10    'ElasticNet': ElasticNet(alpha=0.15, l1_ratio=0.5)
11 }
12
13 for name, model in models.items():
14     pipe = Pipeline([('prep', preprocessor), ('reg', model)])
15     pipe.fit(X_train, y_train)
16     y_pred = pipe.predict(X_test)
17     print(f"{name}: R2={r2_score(y_test, y_pred):.4f}")
```

Listing 3: Bloque 5: Pipeline de Modelos Predictivos

```
1 # Normalidad
2 jb_stat, jb_pval = stats.jarque_bera(residuals)
3
4 # Homocedasticidad
5 bp_stat, bp_pval, _, _ = sm.stats.diagnostic.het_breuschpagan(
6     residuals, X_design)
7
8 # Multicolinealidad
9 from statsmodels.stats.outliers_influence import
10     variance_inflation_factor
11 vif = [variance_inflation_factor(X_design, i)
12         for i in range(X_design.shape[1])]
13
14 # Independencia
15 dw = sm.stats.stattools.durbin_watson(residuals)
```

Listing 4: Bloque 6: Validacion de Supuestos